

Dateien analysieren

Dateien analysieren

- ana erstellt Statistiken der Verteilungen von Byte-Folgen in Dateien
- die erste Version des Programms analysiert nur Byte-Folgen der Länge eins
- also die Häufigkeiten der einzelnen Bytes
- das Programm wird später für beliebige Byte-Folgen fester Länge erweitert

- die Funktion `main` wertet Argumente der Kommandozeile aus
- dann liest `main` die Standard-Eingabe komplett und wertet sie aus
- zum Schluss schreibt `main` die resultierende Statistik in die Standard-Ausgabe

```
@Def(file: ana.cpp)
@put(main prereqs);
int main(
    int argc, const char *argv[]
) {
    @Put(parse args);
    @put(read input);
    @put(write table);
}
@End(file: ana.cpp)
```

Datenstruktur für Statistik

Datenstruktur für Statistik

- für jedes gelesene Byte wird gezählt, wie häufig der Byte-Wert in der gelesenen Eingabe vorkommt

- für jedes Byte wird ein eigener Zähler benutzt
- später wird die `Collection` umdefinieren
- daher ist die Definition in einem eigenen globalen Fragment gekapselt

```
@Def(def collection)
  using Collection =
    std::map<char, int>;
@End(def collection)
```

- es gibt eine globale Variable, welche die Häufigkeiten enthält

```
@def(main prereqs)
  #include <map>
  @Put(def collection);
  Collection collection;
@end(main prereqs)
```

- benötigt Standard Ein- und Ausgabe

```
@add(main prereqs)
  #include <iostream>
@end(main prereqs)
```

```
@def(read input)
  @Put(init state);
```

- jedes gelesene Zeichen wird in die Statistik integriert

```
char ch;
while (std::cin.get(ch)) {
    @Put(add to collection);
}
@end(read input)
```

- später benötigt das Programm einen Ort, um den aktuellen Schlüssel zu initialisieren
- das passende Fragment wird schon vorab definiert
- aber nicht gefüllt

- fügt Zeichen in die Statistik ein
- eigenes globales Fragment, um es später zu ersetzen

```
@Def(add to collection)
    ++collection[ch];
@end(add to collection)
```

```
@def(write table)
    for (const auto &e : collection) {
        @Put(write key);
        std::cout << "\t" <<
            e.second << "\n";
    }
@end(write table)
```

- jeder Eintrag der Statistik wird ausgegeben

- druckbare Zeichen werden direkt ausgegeben
- andere Bytes werden escaped
- so können Unix-Tools die Datei in Spalten aufteilen

```
@add(main prereqs)
#include <cctype>
void write_byte(char b) {
    if (isprint(b) &&
        b != '%' && b > ' ')
    {
        std::cout << b;
    } else {
        @put(write escaped);
    }
}
@end(main prereqs)
```

```
@def(write escaped)
  static const char digits[] {
    "0123456789abcdef"
  };
  std::cout << '%' <<
    digits[(b >> 4) & 0xf] <<
    digits[b & 0xf];
@end(write escaped)
```

- andere Bytes werden mit dem Präfix % als zwei hexadezimale Ziffern ausgegeben
- auch das Zeichen % muss so kodiert werden

- gibt den Schlüssel aus
- eigenes Fragment, da sich der Typ des Schlüssels später ändert

```
@Def(write key)
  write_byte(e.first);
@end(write key)
```